

LAPORAN UTS
MANAJEMEN INFORMASI

**Dosen Pengampu :
Dr. Ir. Iwan Binanto**



Disusun oleh:

GABRIELLA NAVA TRIVANA IRIANTO

245314069

KELAS C

**PROGRAM STUDI INFORMATIKA
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS SANATA DHARMA
YOGYAKARTA
2026**

Bagian 1: Pengertian Data (Data Understanding)

1. Klasifikasi Tipe Data

NO	Nama Kolom	Representasi Dunia Nyata
1	Session_ID	Identitas unik untuk membedakan satu sesi kunjungan dengan sesi lainnya.
2	Duration_ID	Total waktu (detik) yang dihabiskan pengguna selama berinteraksi di aplikasi.
3	Click_Count	Frekuensi atau rasio aktivitas klik yang dilakukan oleh pengguna.
4	Scroll_Depth	Persentase sejauh mana pengguna menggulir halaman (konten) ke bawah.
5	Typing_Speed	Kecepatan rata-rata pengguna dalam mengetik (karakter/kata per menit).
6	App_Version	Versi perangkat lunak yang digunakan (merepresentasikan rilis fitur tertentu).
7	Rating_Given	Feedback subjektif berupa tingkat kepuasan yang diberikan pengguna.

2. Klasifikasi Tipe Data

Nama Kolom	Tipe Data	Skala Pengukuran	Alasan
Session_ID	Kualitatif	Nominal	Hanya sebagai label pengenalan tanpa urutan logis.
Duration_Sec	Kuantitatif	Ratio	Memiliki nilai nol mutlak dan dapat dihitung rasionya.
Click_Count	Kuantitatif	Ratio	Menyatakan jumlah/frekuensi aktivitas dengan titik nol.

Nama Kolom	Tipe Data	Skala Pengukuran	Alasan
Scroll_Depth	Kuantitatif	Ratio	Persentase jangkauan konten (0-100%).
Typing_Speed	Kuantitatif	Ratio	Kecepatan numerik yang dapat dibandingkan secara matematis.
App_Version	Kuantitatif/Kualitatif	Interval	Urutan versi menunjukkan perkembangan waktu/fitur.
Rating_Given	Kualitatif	Ordinal	Memiliki tingkatan (Low < Medium < High).

3. Struktur Data

Data disusun dalam format baris dan kolom. Setiap atribut memiliki tipe data yang jelas dan konsisten, serta disimpan dalam format .csv yang memudahkan pemrosesan menggunakan SQL atau DataFrame (Pandas).

Bagian 2: Deskripsi Data (Data Description)

1. Statistik Deskriptif

Statistik Deskriptif Kolom Numerik:

	mean	median	std	min	max
Session_ID	2551.763552	2553.00	897.479782	1001.00	4100.00
Duration_Sec	4.989202	4.98	2.909399	0.00	10.00
Click_Count	0.507632	0.51	0.288029	0.00	1.00
Scroll_Depth	50.443635	51.01	28.829910	0.03	99.99
Typing_Speed	505.886053	506.76	285.486332	0.20	999.63
App_Version	0.490891	0.49	0.284693	0.00	1.00


Analisis :

Data memiliki distribusi yang sangat simetris. Hal ini terlihat dari nilai Mean dan Median yang hampir identik di setiap kolom numerik. Standar deviasi yang cukup besar menunjukkan bahwa data tersebar merata (tidak mengumpul di satu titik saja).

2. Analisis Anomali

- Session_ID Duplikat: Ditemukan 92 entri dengan ID yang sama. Ini menunjukkan adanya kesalahan teknis saat pencatatan sesi di aplikasi.
- Missing Values: Terdapat 93 baris yang sepenuhnya kosong atau memiliki nilai NaN di hampir semua kolom.
- Logika Data: Nilai minimum dan maksimum berada pada rentang yang wajar (contoh: Durasi 0-10 detik, Klik 0-1). Tidak ditemukan anomali berupa nilai negatif pada durasi atau kecepatan ketik.

3. Visualisasi Distribusi



Histogram menunjukkan bahwa kolom Duration_Sec berdistribusi secara Seragam. Tidak ada kemiringan yang berarti, yang menandakan bahwa durasi interaksi pengguna terdistribusi secara adil antara 0 hingga 10 detik.

Bagian 3: Pembersihan Data (Data Cleaning)

1. Penanganan Missing Values

```

Data setelah pembersihan awal:
<class 'pandas.core.frame.DataFrame'>
Index: 2916 entries, 0 to 3099
Data columns (total 7 columns):
  #   Column          Non-Null Count  Dtype
---  -
0    Session_ID      2916 non-null   float64
1    Duration_Sec     2916 non-null   float64
2    Click_Count      2916 non-null   float64
3    Scroll_Depth     2916 non-null   float64
4    Typing_Speed     2916 non-null   float64
5    App_Version      2916 non-null   float64
6    Rating_Given     2916 non-null   object
dtypes: float64(6), object(1)
memory usage: 182.2+ KB

```

- identifikasi: Sekitar 3% data bernilai NaN.
- Strategi:
- Kolom numerik diisi menggunakan Median untuk mempertahankan distribusi pusat.
- Baris dengan Rating_Given kosong dihapus untuk menjaga akurasi analisis sentimen/kategori.
- Alasan: Jumlah data yang hilang relatif kecil, sehingga imputasi median adalah cara teraman untuk menghindari bias dari pencilan.

2. Standardisasi Teks

```
Kategori unik Rating_Given: ['High' 'Unknown' 'Medium' 'Low']
```

- Langkah: Melakukan `.strip()` untuk menghapus spasi liar dan `.capitalize()` untuk memastikan penulisan kategori konsisten (contoh: "high", "High ", dan "HIGH" semuanya menjadi "High").
- Hasil: Kategori sekarang konsisten menjadi: High, Medium, Low, dan Unknown.

3. Deteksi Outlier (IQR)

- Hasil: Berdasarkan metode *Interquartile Range* (IQR), tidak ditemukan nilai yang berada di luar batas bawah maupun batas atas
- Keputusan: Semua data dipertahankan karena mencerminkan variasi perilaku pengguna yang asli dan bukan merupakan *error* input.

Bagian 4. Transformasi Data (Data Transformation)

1. Feature Scaling :

Pada tahap ini, dilakukan normalisasi menggunakan Min-Max Scaling untuk mengubah rentang nilai pada kolom numerik (Duration_Sec, Click_Count, Scroll_Depth, Typing_Speed) menjadi skala 0 hingga 1.

Hasil Scaling (5 Baris Pertama):

	Duration_Sec	Click_Count	Scroll_Depth	Typing_Speed
0	0.231	0.43	0.882153	0.506849
1	0.200	0.04	0.536715	0.909318
2	0.840	0.18	0.564926	0.386140
3	0.701	0.22	0.144558	0.295458
4	0.484	0.98	0.840236	0.520577

2. Encoding Data Kategorikal :

Untuk kolom Rating_Given, dipilih metode Ordinal Encoding.

Transformasi:

- High → 3
- Medium → 2
- Low → 1
- Unknown → 0

Alasan Pemilihan Metode:

Data Rating_Given bersifat Ordinal, artinya terdapat urutan tingkatan yang bermakna (High lebih tinggi dari Medium, dst). Ordinal encoding mempertahankan hubungan hierarki ini dalam bentuk angka. Sebaliknya, One-Hot Encoding kurang tepat di sini karena akan menghilangkan informasi urutan dan menambah dimensi kolom secara tidak perlu.

	Rating_Given	Rating_Score
0	High	3
1	Unknown	0
2	Medium	2
3	Low	1
4	Low	1

3. Feature Engineering :

Fitur ini memberikan wawasan tentang intensitas interaksi pengguna. Pengguna dengan Engagement_Index tinggi adalah mereka yang melakukan banyak aktivitas dalam waktu yang relatif singkat. Hal ini membantu tim produk

membedakan antara pengguna yang "hanya membuka aplikasi" (durasi lama tapi aktivitas rendah) dengan pengguna yang aktif berinteraksi.

	Session_ID	Engagement_Index
0	1001.0	1.145999
1	1002.0	0.071562
2	1003.0	0.108177
3	1004.0	0.039704
4	1005.0	1.409985

Kesimpulan

Dataset User Engagement App awalnya memiliki beberapa masalah teknis, seperti adanya data yang terduplikasi, kolom yang kosong, dan format tulisan yang tidak seragam. Hal ini wajar terjadi pada data mentah, namun jika tidak diperbaiki, dapat menyebabkan hasil analisis yang salah.

Setelah dilakukan pembersihan dan transformasi:

1. Data menjadi lebih akurat: Semua data duplikat dan baris kosong telah dihapus atau diperbaiki, sehingga informasi yang dihasilkan lebih terpercaya.
2. Data lebih adil: Dengan penyamaan skala (scaling), fitur yang angkanya besar (seperti kecepatan mengetik) tidak lagi mendominasi fitur yang angkanya kecil (seperti jumlah klik).
3. Lebih kaya informasi: Adanya fitur baru seperti Engagement Index memudahkan kita melihat pengguna mana yang benar-benar aktif menggunakan aplikasi, bukan sekadar membukanya saja.

Hasilnya, kualitas dataset meningkat dari data mentah yang berantakan menjadi data yang rapi, konsisten, dan siap digunakan untuk kebutuhan pengambilan keputusan bisnis maupun pembuatan model prediksi yang akurat.